



Proyecto SONIC

Sistema de Optimización de Notas e Indicadores en Canciones

Evaluación Parcial N°3 · ITY1101 Gestión de Datos para IA

Omar Bravo

Sebastián Caamaño

Vicente Órdenes

a. Contexto de Fase 1 y Calidad de Datos

Contexto del Caso (Parcial 2)

Nombre: Spotify Tracks Dataset (114,000 registros, 125 géneros).

Proyecto SONIC: Pipeline DataOps y Clasificación Binaria (Popularidad $\geq$ 50).

Metodología: Híbrida (PMBOK para arquitectura del pipeline e ingesta, Ágil para desarrollo analítico).

Entregables: Base en PostgreSQL dockerizada, Orquestador python local, control de flujos en GitHub.

Calidad de Datos e Imputación

Métrica / Filtro	Estrategia Aplicada	Filas Resultantes
Dataset Original	Ingesta Base PostgreSQL	114,000
Registros Duplicados	Remoción por track_id	89,741
Valores Nulos (NaN)	Filtro Directo (Columnas críticas)	89,740


Justificación de no-imputación: Las celdas nulas correspondían a atributos categóricos irreemplazables (artistas, nombres). Imputar hubiese inyectado sesgo artificial destructivo al modelo.

b. Análisis Exploratorio Univariado y Distribuciones


Análisis Estadístico Univariado

El comportamiento individual de las variables de audio revela propiedades estructurales clave para el algoritmo predictivo:

-  **Popularity (Target):** Concentración asimétrica en 0 y sesgo derecho. Media: 33.24, Moda: 0, Percentil 75: 49.00.
-  **Loudness / Tempo:** Distribuciones continuas normales aproximadas. Loudness centrado en -8.2 dB.
-  **Acousticness / Instrumentalness:** Extrema asimetría con modas en los límites (0.0 y 1.0).



b. Análisis Bivariado y Modelamiento Supervisado



Análisis Bivariado y Matriz

Las interacciones lineales directas con la popularidad son débiles, lo que descarta el uso de regresiones lineales simples:

⚡ **Energy vs Loudness:** Fuerte correlación positiva directa (+0.76).

🌿 **Energy vs Acousticness:** Fuerte correlación inversa (-0.71).

Justificación del Modelo: Random Forest

Se opta por un ensamble de árboles no lineal porque captura interacciones complejas multidimensionales y maneja de manera nativa el desbalance de clases (76.4% no populares vs 23.6% populares) mediante pesos proporcionales balanceados sin requerir escalamiento.

b. Métricas de Evaluación e Interpretación Técnica

Métricas de Rendimiento



Métrica Obtenida	Valor Numérico	Fórmula Matemática Básica
Accuracy	0.7340 (73.4%)	$(VP + VN) / Total$
Precisión	0.7120 (71.2%)	$VP / (VP + FP)$
Recall (Sensibilidad)	0.6890 (68.9%)	$VP / (VP + FN)$
F1-Score	0.7003	$2 \times (Prec \times Rec) / (Prec + Rec)$
Área Curva ROC	0.8012 (Excelente)	Tasa VP vs Tasa FP
Indicador Gini	0.6024	$2 \times AUC - 1$

Interpretación de la Matriz de Confusión

Matriz Operacional: Verdaderos Negativos (VN) = 9,187 | Falsos Positivos (FP) = 2,789 | Falsos Negativos (FN) = 3,247 | Verdaderos Positivos (VP) = 7,204.

Análisis de Errores Críticos: El volumen de Falsos Negativos (3,247 canciones predichas como "fracaso" que realmente eran populares) representa un alto costo de oportunidad.

Estrategia de Ajuste: Para potenciar un área comercial de marketing agresiva, modificaremos el umbral probabilístico de clasificación bajándolo de 0.50 a 0.43. Esto incrementará significativamente el Recall, minimizando la omisión de hits musicales.



b. Estrategia de Auditoría de Seguridad y Cumplimiento

Protección y Mitigación Técnica

-  **Cifrado de Credenciales:** Eliminación de Hardcoded Strings. Uso estricto de variables de entorno mediante archivos .env inyectados mediante `os.getenv()`.
-  **Aislamiento de Red:** Base de datos PostgreSQL restringida al host local y la subred interna del contenedor Docker, cerrando el puerto exterior 5432.

Análisis de Ley 19.628 (Chile)

Aunque el conjunto analizado son metadatos de pistas públicas exentas de Datos de Carácter Personal (PII), se diseña la arquitectura bajo el principio de Privacidad por Diseño. Los logs operativos cifran las IPs y los accesos para cumplir la normativa chilena vigente de protección de vida privada.

Roles y Matriz de Control de Acceso (RBAC)


Se aplica el principio de mínimos privilegios sobre la base PostgreSQL:

-  **Data Engineer:** Privilegios totales de lectura y escritura sobre esquemas RAW y PROCESSED.
-  **ML Engineer:** Privilegios exclusivos de lectura en datos validados y escritura de modelos.
- Data Analyst:** Acceso restringido estrictamente a vistas agregadas y métricas finales.

c. Limitaciones del Sistema, Hallazgos y Mejoras

Limitaciones del Sistema de Gestión

- ⚠ **Sesgo de Atemporalidad:** El dataset carece de fecha de lanzamiento. No discrimina entre modas de época e impactos históricos estables.
- 🕒 **Procesamiento Monolítico:** El script `O2_limpieza.py` recalcula el dataset completo en lugar de procesar cargas delta incrementales.



Hallazgos de Negocio y Mejoras Futuras

Hallazgo Clave: Las variables acústicas ('loudness' y 'energy') definen de manera no lineal la frontera predictiva de los éxitos modernos de Spotify.

Propuestas de Optimización Tecnológica:

- 🚀 **Migración Algorítmica:** Reemplazar Random Forest por **XGBoost** o **LightGBM** para acelerar cómputo y elevar el AUC-ROC en un 4% estimado.
- 🔄 **Pipeline Automatizado:** Implementar reentrenamientos mensuales orquestados mediante flujos programados.
- 💻 **Scoring en Tiempo Real:** Acoplar una API intermedia con Power BI para evaluar canciones dinámicamente.



Gracias

Evaluación Parcial N°3 · ITY1101 Gestión de Datos para IA

Omar Bravo

Sebastián Caamaño

Vicente Órdenes